

SPLETNI PAJEK

Anja Brelih, Ana Knafelc, Eva Vidmar

Fakulteta za računalništvo in informatiko, Univerza v Ljubljani

1 Uvod

Pri prvem projektnem delu pri predmetu Iskanje in ekstrakcija podatkov s spleta je bila naša naloga implementirati večnitnega spletnega pajka z iskanjem v širino po domeni "gov.si". Cilj projektnega dela je, poleg zbrati podatke iz 50.000 spletnih strani v domeni, nalogo opraviti tudi etično. Torej spletni pajek upošteva omejitve domen, ki jih dostopa, da se izognemo napadu zavrnitve storitve (*angl. Denial of Service - DoS*), oziroma distribuirani različici napada, glede na to, da je enako nalogo v istem času opravljalo več študentov.

2 Implementacija


Pajak ob zagonu preveri, če obstajajo *url*-ji v *frontier*-ju ter v kolikor jih ni ustavi semena v podatkovno bazo z značko FRONTIER ter pogleda njihovo domene in pridobi informacije iz *robots.txt* datoteke (*crawl-delay*, *sitemap* ter *disallow*) ter tudi to zabeleži v bazo. V tabeli domen v podatkovni bazi smo dodali tudi stolpec, ki zapiše zadnji čas dostopa v domeno, ki se redno posodablja, da se izognemo prepogostim klicem v domeno. Naslednji korak je aktiviranje globalno definirane števila niti s pomočjo objekta niti. Ko se niti zaženejo, po vrstnem redu iskanja v širino iz podatkovne baze pridobijo *url*-je. Najprej se preveri, če se glede na *crawl-delay* in čas zadnjega dostopa v domeno spletno stran že lahko dostopa, v kolikor ne, počaka primeren čas. Spletno stran najprej dostopamo z *Requests*, da pridobimo informacije glede tipa spletne strani. V kolikor je spletna stran tipa HTML po pretečenem času *crawl-delay-a* do nje dostopamo še enkrat s *Selenium*, da pridobimo html vsebino. Podatki spletne strani se nato zabeležijo v podatkovno bazo, html vsebina pa gre naprej v iskanje novih *url*-jev, ki jih pridobimo glede na značke *href*, *button* ter *img*. Potencialne *url*-lje je potrebno nato še prečistiti, kanonizirati, pregledati njihove domene ter vse skupaj zabeležiti v podatkovno bazo, kjer se hranijo le unikatni *url*-lji. Tik preden spletno stran zabeležimo v podatkovno bazo, pridobimo *hash* vsebine spletne strani z zgoščevalno funkcijo s katerim preverimo, če identična vsebina v podatkovni bazi že obstaja. V tem primeru se stran klasificira kot DUPLIKAT ter se to primerno zabeleži v podatkovni bazi. V kolikor je po poizvedbi *Requests* spletna stran klasificira kot BINARY se glede na kodo spletne strani pogleda tip je datoteke na katero vodi *url* ter informacijo zabeležimo v podatkovno bazo. Ob tem je delo niti zaključeno in se celoten proces ponovi.

3 Pridobljeni podatki

S spletnim pajkom smo pri prvi implementaciji pridobili približno 23.000 *url*-jev, kjer se je pajek ustavil zaradi nepravilnega čiščenja *url*-jev. Odločile smo se, da popravimo napake, pobrišemo pridobljene podatke ter pajka zaženemo še enkrat od začetka, zato pajek ni dosegel načrtovanega števila vsebin spletnih strani. Število pridobljenih spletnih strani glede na tip je zapisano v spodnji tabeli. V frontirju nam je ostalo še približno 31.000 *url*-jev.

	Količina
Domene	272
Spletne strani	18.328
HTML	12.571
Error	1.913
Duplikat	299
PDF	1.080
DOC, DOCX	800
PPT, PPTX	4
Slike	1531

V začetku smo imele podane štiri semena. Iz semena "*www.gov.si*" smo pridobile 9.526 strani, iz "*www.evem.gov.si*" 108 strani, iz "*www.e-uprava.gov.si*" 1.728 strani ter iz semena "*www.e-prostor.gov.si*" 521 strani.



Slika 1: Vizualizacija prepletenosti *url*-jev

4 Zaključek

Največji problem pri projektu je bil vzpostaviti več-nitnost. Poskusile smo več različnih metod, vendar se je vse do zadnje dogajalo to, da so si niti med sabo "kradlešpremenljivke in je zato v začetku posodobljene podatkovne baze nekaj spletnih strani zabeleženih kot duplikat, čeprav to niso. Pri prvi implementaciji nam je težave povzročalo preverjanje SSL certifikata tako pri *Requests*, kot

pri *Selenium*, zato vsebine strani nismo prejele, kar je eden od razlogov, zakaj je pri prvem poskusu zmanjkalo *url*-jev. Drugi problem pa je bil neprimerno čiščenje *url*-jev, na neprimerni točki smo potencialni *url* preverjale, če ta sodi v katero od domen "*gov.si*". Pri novi izvedbi smo tudi podrobneje pregledale iskanje potencialnih *url*-jev s knjižnico *Selenium*, da upoštevamo tudi relativne *url*-je. Kar nekaj težav nam je povzročala povezava s podatkovno bazo, zato tudi sama končna implementacija vsebuje več poizvedb kot bi bilo potrebno za pridobitev želenih informacij. Dilema je bila tudi na temo tega, ali naj povezave z bazo ustvarimo globalno glede na število niti ali naj povezavo odpiramo in zapiramo pri vsakem klicu. Končna implementacija vsebuje odpiranje in zapiranje podatkovne baze ob vsakem klicu skupaj z zaklepanjem. Nekaj težav se je pojavljalo tudi pri prepoznavi tipa dokumenta, vsi dokumenti so bili na koncu zabeleženi še kot DOCX. Da smo prišle do končne implementacije, ki deluje, kot je zahtevano, smo porabile veliko časa in testiranja, zato ob koncu projekta nismo pridobile vseh zahtevanih strani.

Literatura

1. Level Up Coding, Multi-Threaded Python Web Crawler for HTTPS pages. <https://levelup.gitconnected.com/multi-threaded-python-web-crawler-for-https-pages-e103f0839b71>. Dostopano: 28.3.2022
2. Selenium. <https://selenium-python.readthedocs.io/>. Dostopano: 25.3.2022
3. Psycopg. <https://www.psycopg.org/docs/>. Dostopano: 26.3.2022
4. Requests. <https://docs.python-requests.org/en/latest/>. Dostopano: 25.3.2022